Jav1es • 黄家辉

企业级 AI Agent 开发工程师

广州　1459393754@qq.com　13501519949　微信 13501519949　github.com/Jav1es (https://github.com/Jav1es)
jav1es.github.io/portfolio (https://jav1es.github.io/portfolio/)

> 6 年+ 企业科技服务（2021.04 至今），主导 300+ 项目、服务 100+ 企业（项目申报口径）。AI 工程实践 27 个月：把 AI Agent 从 Demo 做到生产——RAG 检索 93.3% @3，OTel/Jaeger 全链路可观测，9 个公开开源仓库、CI 运行中。

6 年+ 企业科技服务	**27 个月** AI 工程实践	**300+** 主导项目
100+ 服务企业	**93.3%** RAG 准确率 @3	**9** 公开开源仓库（MIT）

技能矩阵

AI Agent 开发
六层智能体架构 · LangGraph 五阶段编排 · 工具调用与运行时防护 · 双视野记忆（Redis / PostgreSQL） · MCP 协议与 Server 实现 · FastAPI + SSE 流式接口

RAG 与检索
语义边界切分 · Dense / BM25 混合检索 · RRF 融合 · Cross-Encoder 重排 · 附引用降幻觉 · 30 题分层评测（@3 93.3%）

评测与可观测性
评测集纳入 CI 回归 · OpenTelemetry 埋点 · Jaeger 全链路追踪 · LLM 延迟分解 · Locust 阶梯压测 · Prompt 模板库 + Schema 校验

工程化与部署
Python / FastAPI · Docker Compose · K8s Helm（HPA / 探针 / Secret） · Redis / PostgreSQL / pgvector · GitHub Actions CI · pytest / vitest

FDE 交付与项目管理
客户现场需求发现 · Discovery Brief 范围定义 · Eval Plan 验收口径 · RACI 与里程碑管理 · SOP 与客户培训 · 项目信息数据库与监测报告

前端与工具链
HTML5 / CSS3 / 原生 JS · 响应式与可访问性（a11y） · 3D 视觉与动效 · Node.js ESM · Service Worker / PWA · PowerShell 自动化

工作经历

广东科友商务集团 / 广州市科运商务信息咨询有限公司

2021.04 – 至今

项目主管（项目申报技术咨询师）

- 主导客户项目全生命周期：需求调研、痛点诊断与可行性分析，输出《合作可行性分析报告》并制定实施技术路线；累计交付政府/企业项目 300+、服务企业 100+。
- 主导技术方案设计与交付材料编制，组织合规性自查并跟进审批；单年最高通过国家级高新技术企业认定 24 家、单年通过项目 60+，曾 1 周内完成从签单到申报的交付。
- 搭建项目信息数据库（业务知识库雏形），输出《项目监测报告》，以数据驱动方案迭代与管理决策。
- 将 Coze + 多维表 AIGC 工作流与「AI 预处理 + 人工审核」机制引入业务，配套 SOP / FAQ 与采纳率反馈闭环。
- 面向客户与内部团队开展政策解读、系统操作培训与现场实施指导。

精选项目

企业级智能体系统（enterprise-agent）

独立设计与开发

- 主导企业级智能体系统建设，采用六层架构集成 RAG、工具调用与 MCP，基于 LangGraph StateGraph 实现 Router → Planner → Skill → Tool → Reviewer 五阶段编排，RAG 检索准确率达 93.3% @3（30 题分层评测）。
- 建立评测集并纳入 CI 每次 push 自动回归，结合 OpenTelemetry + Jaeger 全链路追踪（一次会话 7 个 span：root · router · planner · retrieve · tool_call · reviewer · respond），将 Agent 稳定性问题的定位时间从小时级降到分钟级。
- 完成服务端工程化：FastAPI + SSE 流式接口、Pydantic 结构化输出、重试/降级/熔断中间件；Docker Compose 一键起全栈，K8s Helm 配双指标 HPA 与健康探针。

技术栈：LangGraph · RAG · MCP · FastAPI · Redis · PostgreSQL · K8s

GitHub (https://github.com/Jav1es/enterprise-agents)　案例详情

RAG 知识库与检索质量评测

独立设计与开发

- 针对企业知识问答的检索准确率问题，实现语义边界智能切分（chunk 500 / overlap 50）+ Dense / BM25 混合检索 + RRF 融合 + Cross-Encoder 重排，生成结果强制附条款引用以降低幻觉。
- 建立 30 题分层评测集实测检索准确率 @3 达 93.3%（@1 73.3%），并沉淀为可复现的评测报告（含重排对照与幻觉分析）。
- 在评测中发现 RRF 融合分数不可直接用作拒答阈值，改用「强制带引用验证」方案，避免低置信回答被误放行。

技术栈：RAG · 混合检索 · RRF · Cross-Encoder · 评测集

评测报告 (https://github.com/Jav1es/enterprise-agents)　案例详情

MCP Server 三件套（开源）

独立设计与开发

- 把 3 个可独立复用的 MCP Server 开源到 GitHub（工具调度 / 作品集检索 / RAG 知识问答），实现标准化的工具发现与函数调用，接入 ERP / CRM / OA / 钉钉 / 企微等多系统。
- 配套 pytest 35 个用例全部通过，本地可一键运行，附完整 README 与使用文档。
- 沉淀为可复用的开源资产，使后续项目接入新系统时无需重复实现工具协议层。

技术栈：MCP · 工具调用 · pytest · 开源

GitHub (https://github.com/Jav1es/enterprise-agents)　案例详情

FDE 交付物模板：Discovery Brief × Eval Plan 独立编写（自编模板与演练稿，非客户委托交付）

- 面对客户现场交付范围靠口头约定、上线后无验收标准的问题，把「进客户门 → 诊断缺口 → 形成可验证交付范围」与「上线前怎么验证、上线后怎么监控」沉淀成两份标准件。
- Discovery Brief 按「业务现状 → 痛点归类 → 可验证范围 → 验收口径」四段式组织；Eval Plan 按「评测集分层 → 指标定义 → 门禁阈值 → 回归触发 → 监控看板」五段式组织。
- 以脱敏台账为输入做演练并据此修订模板结构，沉淀为可复用标准件，把「我以为客户需要」变成「客户确认过需要」。**当前为演练稿，待客户现场核验**（文件自身状态亦为「草稿」）。

技术栈：FDE · 需求发现 · 验收口径 · SOP

模板全文　案例详情

开源与影响力

9 个公开仓库（9 个 MIT）——9 个公开仓库（全部 MIT 许可），覆盖 MCP 协议桥接、宿主插件、运维工具链、离线 PWA 与检索规程。

enterprise-agents Python
企业级智能体系统：六层架构 + RAG 混合检索（30 题评测 93.3%@3）+ Helm + 压测

dsh-bridge JavaScript
让腾讯 Marvis 调用本机 DeepSeek Harness：Skill + MCP 两种接入

dsh-local-plugins JavaScript
三个自建 DSH 本机插件：微信推送 / 图片与 PDF 预览 / Todo 与 Thinking 面板

dsh-prompt-compiler JavaScript
可编程 prompt 编译层：把粗糙草稿编译成结构化 prompt（analyze→elicit→compile）

dsh-toolkit PowerShell
DSH 运维工具箱：升级自检 + 插件兼容预检 + 生态全量调研

dsh-knowledge-guide Markdown
检索路由与回答规程 skill：先检索再作答、强制标来源、未命中先做正对照

workbuddy-bridge JavaScript
让 Marvis 把本机 WorkBuddy 当子 Agent 调用的 MCP 桥接层

dsh-skills Markdown
可复用 Agent Skills 集合：知识检索规程 / 简历 JD 适配 / 静态站搭建

教育背景

广东邮电职业技术学院 计算机应用技术（电子与信息大类 · 大专） 2019.09 – 2022.06

本科（自考）在读，预计 2027 毕业。

证书

已取得：计算机中级（计算机技术与软件专业技术资格）、全国计算机应用技术证书、办公自动化应用师
备考中：信息系统项目管理师（软考高级）、PMP

成效类数字均已标注口径（实测 / 测算模型 / 示例口径）；客户名称与年度数据一律脱敏。本页可直接下载 PDF，或按 Ctrl / Cmd + P 打印。